

AI for Science

심층 학습과 과학적 발견의 교차점

강연자: Chris Bishop | Microsoft Research AI for Science 창립 이사 · Technical Fellow

출처: Introduction to Deep Learning 2026 초청 강연

1. 도입 — 수학으로 기술되는 세계

Bishop은 과학이 이루어낸 가장 놀라운 발견 중 하나로 "우리가 사는 세계가 수학으로 기술된다"는 사실을 꼽는다. 전자기학, 양자역학 등 몇 가지 간결한 방정식만으로 일상에서 경험하는 거의 모든 현상을 설명할 수 있으며, 이 방정식들은 전자 자기 모멘트를 소수점 13자리까지 예측하는 수준의 정밀도를 자랑한다.

문제는 방정식이 존재하더라도 풀 수가 없다는 점이다. 대기, 소재, 신약 설계 등 수많은 분야에서 지배 방정식은 이미 알려져 있지만, 그 풀이는 계산적으로 감당하기 어려운 만큼 복잡하다. Dirac은 1929년에 이미 이 아이러니를 지적했다.

"...The difficulty is only that the exact application of these laws leads to equations much too complicated to be soluble."

— Paul Dirac (1929)

2. 과학적 발견 과정과 AI의 역할

전통적인 과학의 반복 루프는 가설 수립 → 실험 → 관측 → 가설 수정으로 이루어진다. 1960년대 디지털 컴퓨터의 등장으로 시뮬레이션이 실험을 보완하는 세 번째 경로로 자리잡았다. 이제 AI는 가설 생성, 실험 데이터 분석, 자동화 실험실 구동, 방대한 논문 처리 등 발견 과정 전반에 관여하고 있다.

Microsoft의 Discovery Platform은 대형 언어 모델 기반의 에이전트형 플랫폼으로 이 과정을 가속하는 데 활용되고 있다. Bishop은 이번 강연에서 그와는 별개의 접근 방식, 즉 AI 에뮬레이터에 집중한다.

3. 핵심 개념 — AI 에뮬레이터

No Free Lunch 정리와 귀납적 편향

No Free Lunch 정리에 따르면, 순수한 데이터만으로는 학습이 불가능하다. 모든 예측은 데이터와 사전 가정(귀납적 편향)의 결합을 필요로 한다. 대형 언어 모델은 방대한 데이터를 활용하되 가벼운 귀납적 편향(어텐션 메커니즘)을 사용한다. 반면 과학은 데이터가 희소하지만 방정식이라는 강력한 사전 지식을 보유하고 있다.

에뮬레이터의 작동 원리

에뮬레이터의 핵심 발상은 시뮬레이터의 역할을 신경망으로 대체하는 것이다. 시뮬레이터(기존 수치 해석 소프트웨어)로 다수의 시스템을 계산하여 합성 학습 데이터를 생성하고, 이 데이터로 신경망을 훈련시킨다. 훈련된 에뮬레이터는 시뮬레이터와 동등한 결과를 수천 배 빠르게 산출한다.

특징	내용
데이터 품질	자동 레이블링, 개인정보 문제 없음
데이터 양	계산 자원이 허용하는 한 무한 생성 가능

특징	내용
속도 향상	시뮬레이터 대비 통상 1,000배 이상
계산 비용	프런티어 LLM 훈련에 비해 훨씬 저렴

Bitter Lesson과의 관계

Rich Sutton의 Bitter Lesson(2019)은 "결국 더 많은 데이터와 계산이 정교한 사전 지식을 이긴다"고 주장한다. 에뮬레이터 접근법은 이 교훈을 정면으로 수용한다. 물리 방정식을 신경망 구조에 직접 인코딩하는 대신, 방정식으로 데이터를 생성함으로써 사전 지식을 데이터 스케일링의 형태로 활용한다.

4. 주요 응용 사례

4-1. 날씨 예측

수십 년간 축적된 수치 기상 예측 시뮬레이션 데이터를 활용해 에뮬레이터를 훈련시켰다. Microsoft의 접근 방식은 단일 시뮬레이터가 아닌 다양한 해상도·시간 척도의 데이터를 혼합하여 지구 시스템 파운데이션 모델을 구축하고, 이를 대기 오염 예측 등 개별 과제에 파인튜닝한다. 결과적으로 단일 A100 GPU 1대로 영국의 8일 기상 예보를 1분 안에 생성할 수 있다.

4-2. 재료 생성 — Matagen

Matagen은 이미지 생성의 확산 모델(diffusion model) 원리를 결정 구조에 적용한 조건부 생성 모델이다. 원하는 전자·자기·기계적 특성을 입력하면 해당 특성을 가진 새로운 결정 구조를 생성한다. 이를 통해 광대한 화학 공간 중 탐색할 영역을 좁히고, MatterSim 에뮬레이터로 후속 스크리닝을 수행하면 이중의 가속 효과를 얻는다.

4-3. 정확도-속도-일반성의 트레이드오프

분자·재료 설계에서 핵심 과제는 정확도(화학적 정확도, ~ 1 kcal/mol), 계산 속도, 일반화 능력 세 가지를 동시에 달성하는 것이다. 화학적 정확도란 이론 계산이 실험과 동등한 수준에 도달하는 임계값으로, 분자 전체 에너지 중 반응에 관여하는 에너지는 극히 작은 부분이므로 매우 높은 정밀도가 요구된다.

5. 밀도 범함수 이론(DFT)과 머신러닝

Schrödinger 방정식의 계산 한계

카페인 분자(전자 약 100개)의 파동 함수는 300차원 공간의 함수로, 격자 수치 해석으로 접근하면 격자 수가 전자 수에 따라 지수적으로 증가한다. 이 때문에 카페인 수준의 분자조차 Schrödinger 방정식의 직접 풀이는 현자로서 불가능하다.

Walter Kohn의 DFT — 지수 문제의 정확한 변환

1965년 Walter Kohn은 파동 함수 대신 3차원 전자 밀도만으로 분자의 모든 성질을 계산할 수 있음을 증명했다. 지수적 비용이 전자 수의 세제곱(cubic scaling) 비용으로 정확히 변환된다. 이 업적으로 Kohn은 1998년 노벨 화학상을 수상했으며, DFT는 현재 전국 슈퍼컴퓨터 과학 시뮬레이션 워크로드의 약 3분의 1을 차지한다.

Kohn-Sham 방정식과 교환-상관 범함수 문제

DFT의 실제 구현인 Kohn-Sham 방정식에는 교환-상관 범함수(exchange-correlation functional)라는 미지의 항이 포함된다. Kohn은 이 범함수가 보편적으로 하나 존재함을 증명했지만 그 명시적 형태는 밝히지 못했다. 지난 60년간 800여 개의 수작업 근사 범함수가 개발되었으나, 정확성과 계산 효율을 동시에 갖춘 것은 없었다.

Scafacos — 머신러닝 교환-상관 범함수

Bishop 팀은 3년에 걸쳐 표준 양자 화학 방법으로 기존 공개 데이터 전체보다 10배 많은 고정밀 훈련 데이터를 생성했다. 전자 밀도를 포인트 클라우드로 표현하고, 원자 중심 간 메시지 패싱을 통해 비국소적 의존성을 효율적으로 학습하는 아키텍처를 개발했다(모델명: Scafacos, 이탈리아어로 사다리). 현재 주요 원소 계열 분자에서 화학적 정확도를 달성했으며, 보편 범함수를 학습함으로써 훈련 도메인 외부로의 일반화도 확인되었다.

6. 분자 동역학과 생물학적 스케일 확장

순차성의 저주

분자 동역학은 Newton 제2법칙으로 원자 위치를 시간 순서대로 갱신하는 시뮬레이션이다. 원자 진동 주기(펨토초)에 맞춰 적분 스텝을 잡아야 하지만, 단백질 접힘 같은 생물학적 현상은 밀리초 이상의 시간 척도에서 일어난다. $10^6 \sim 10^{15}$ 번의 순차적 스텝이 필요하며, GPU의 병렬 가속으로 해소할 수 없는 구조적 병목이다.

에뮬레이터 기반 분자 동역학

원자 단위 대신 단백질을 청크(chunk) 단위로 묶어 DFT로 청크 간 힘을 계산하고, 이 데이터로 힘 에뮬레이터(force field emulator)를 훈련한다. 이를 통해 약 10,000개 원자 규모의 단백질에 대한 분자 동역학 시뮬레이션이 가능해졌다.

평형 분포 직접 샘플링 — 생물분자 에뮬레이터

분자 동역학 데이터와 X선 회절 실험 데이터를 결합하여 훈련한 모델은 동역학 시뮬레이션 자체를 생략하고 단백질의 평형 구조 분포를 직접 샘플링한다. 이 연구는 Science 표지 논문으로 발표되었다. 현재는 진공 중 단일 단백질 수준이지만, 향후 단백질-단백질 상호작용 및 수용액 환경으로 확장할 계획이다.

7. 질의응답 — 주요 논점

Q. 일반화 문제: 작은 계에서 훈련한 에뮬레이터가 더 큰 계에 적용 가능한가?

데이터 증강(회전된 분자 복사본)으로 불변성을 학습하는 것이 구조 인코딩보다 Bitter Lesson 관점에서 유리하다. 교환-상관 범함수가 보편적이라는 이론적 사실이 도메인 외 일반화를 뒷받침한다.

Q. No Free Dinner 문제: 시뮬레이션 데이터와 실험 데이터의 관계

실험 데이터는 항상 과학의 궁극적 기준이다. 시뮬레이션 데이터는 DFT에 내재된 물리적 귀납적 편향 덕분에 단순 데이터 이상의 가치를 지닌다. Bitter Lesson의 스케일링 원칙을 방정식 기반 데이터 생성으로 구현하는 방식이다.

Q. 오프타겟 상호작용 예측 및 임상 관련성

전체 세포의 제1원리 시뮬레이션은 수백 년 이내에도 어렵겠지만, 분자 동역학 에뮬레이터를 이용한 약물 오프타겟 독성 예측은 2~3년 내 임상적 기여가 가능할 것으로 전망된다.

8. 결론

AI 에뮬레이터는 과학적 발견의 세 번째 경로를 제공한다. 시뮬레이터로 생성한 합성 데이터에 물리 방정식의 귀납적 편향을 담아내고, 이를 신경망 학습에 활용함으로써 Bitter Lesson과 물리 기반 방법론을 함께 포용한다. 날씨 예측에서 신약 설계, 재료 발견, 단백질 동역학에 이르기까지 수천 배의 계산 가속이 실질적인 과학적 돌파구로 이어지고 있다.

Deep Learning (Bishop & Bishop, 2023) — bishopbook.com에서 무료 열람 가능.